




최종적인 백엔드 서빙 전략

원래 목적

원래 설계는 CPU와 GPU를 분리하여 각 자원의 강점을 살리는 하이브리드 전략이었습니다.

▼ 사진 참고



- CPU: 감정 추출 (YOLO, CLIP, Moondream2) → 병렬 처리
- GPU: MusicGen → 직렬 처리(lock)

CPU/GPU 분리 전략의 목적은 사실 안정성인데

→ GPU 메모리 여유를 확보를 해서 MusicGen 안정성을 보장시켜주기 위해

근데

하지만 문제가 Moondream2 자체가 CPU에서 잘 안 돌아요.....

→ 허깅페이스에 양자화한 Moondream2을 해봐도 잘 안 돌아요.....

→ 그럼 결론적으로 Moondream2도 GPU에서 돌려야 하는 상황

그럼 고민이 드는게 감정 추출 → 뮤직젠 순서가 있고

감정 추출 내 과정에서도 순차적인 의존 관계가 존재하는 상황

- YOLO → 세가지 작업 → 감정 통합

이런 파이프라인 안에서 일부 모델만 GPU, 나머지는 CPU로 올리는 방식이 과연 맞는 설계일까?

- CPU/GPU를 나눠 쓰면 자원 분리라는 명분은 있지만
- 실제로는 중간에 CPU ↔ GPU 간 컨텍스트 전환이 생길 테고 관리하기도 어렵고 그에 따른 성능은? 모르겠음

👉 결과적으로 하이브리드 전략이 이상론적이지, 현실적으로 어차피 어차피 "GPU 올인"으로 갈 수 밖에 없지 않은가?

실제 메모리 원인 분석해보자

VRAM을 잠식하는 진짜 주범은 MusicGen (약 5~6GB).

감정 추출 모델(YOLO/CLIP/Moondream)은 VRAM 사용량이 0.5~1GB 정도라서 미미

그럼 만약 분리 설계로 얻는 VRAM 절감 효과는?

- 만약 감정 추출을 CPU로 옮기면 VRAM을 0.5~1GB 정도 아낄 수 있음
- 하지만 MusicGen이 여전히 5~6GB를 차지하기 때문에, 절감 효과는 상대적으로 미미
- 반면 CPU로 옮길 경우 속도 저하 + 오케스트레이션 복잡성이라는 비용이 발생
- 즉, "안정성"을 이유로 CPU 분리를 택해도 실제 이득은 거의 없음
- 차라리 MusicGen 자체 최적화 OR VRAM 증설 효과 보다는 절감 효과를 보이지 못할 것

대안적인 해결방향

- 하드웨어: 더 큰 VRAM → 배포하자...

- 이미지 전처리: 감정 추출 입력 해상도 축소 (e.g., 512px → 256px), 컬러 채널 압축 → VRAM/메모리 사용량 줄이기 → 미미해
- 모델 최적화: MusicGen FP16/INT8, batch 크기 조정, lazy unload(완료 시 VRAM 해제)
- 그리고 이대로 진행을 할 것이다.
→ 배포 전략: 사용자 단위로 직렬 처리(lock) 유지 → OOM 방지 혹은 워커 수 하나로 제한

GPU로 다 돌렸을 때 메모리 확인하자 + 차 338 기준

로그 기반 처리 시간 분석

1. Ping 로그

16:07:53 → 첫 ping
16:10:23 → 마지막 ping

→ 약 150초 (2분 30초) 동안 SSE 연결이 유지됨.

즉, 전체 파이프라인 (이미지 3장 → 배경음 3개) 처리 시간이 대략 2분 30초였다는 걸 알 수 있음.

2. Partial 이벤트 도착 시간

- 첫 번째 `music_done_partial` : 16:09:00 근처 (약 70초 경과 시점)
- 두 번째 `music_done_partial` : 16:09:55 근처 (약 125초 경과 시점)
- 세 번째 `music_done_partial` : 16:10:20 근처 (약 150초 경과 시점)

👉 각 이미지당 55초 내외 (감정 추출 5초 + MusicGen 50초)

👉 직렬로 큐에서 순차 실행되었음을 확인할 수 있음.

3. 최종 완료 이벤트

id: done-all
→ 마지막 partial 직후 도착

→ 총 3개 이미지 처리 완료 시점 ≈ 150초

시간 추정 결과

- 단일 이미지 처리 시간: ~55초
- 사용자 1명(3장 업로드) 전체 처리 시간: ~165초 (실험 로그에서는 150초)
- Throughput: GPU 1대 기준, 동시 사용자 처리량은 "한 번에 1명(3장)" 수준

메모리 사용량 - 7783MiB / 8188MiB - 95.1%.....

모델 로드를 했을 때 - 추론 X

모델	역할	VRAM 사용량 (로드만)	비고
YOLO (객체 탐지)	이미지 객체 탐지	~0.3 ~ 0.5 GB	경량 모델(v8s) 기준
CLIP + MLP	감정 분석	~0.5 ~ 0.8 GB	멀티모달 임베딩
Face/EMOTIC	얼굴 감정 분석	~0.5 GB	ResNet 기반 추론용 weight
Moondream2	캡션 생성	~0.8 ~ 1.2 GB	LLM 구조라 CPU 불가, GPU 필수
KMeans (색감 감정)	색상 클러스터링	~0 GB	CPU 연산, VRAM 사용 거의 없음
MusicGen	배경음 생성	~2.5 ~ 3.0 GB	모델 weight만 로드, 추론 전

합계 (로드만 했을 때)

- 약 4.6 ~ 6.0 GB
- 즉, 8GB 중 60~75% 차지

추론 시

- MusicGen이 토큰 생성 중에 추가 텐서를 잡아먹으면서 +2~3GB 더 필요
- → VRAM 피크는 7.5 ~ 8.0 GB (≈ 95%)

대안 - MusicGen 때문에

- MusicGen 최적화(FP16, INT8, lazy unload)
- VRAM 더 큰 GPU 사용

배포

- 현재로는 AI 서버에 gpu 돈 몰빵해서
 - 있어빌리티하게
 - api 서버는 우리 컴퓨터
- 한 달내내
- 전시회때만?